Zadanie č. 2c - Klastrovanie

Ruslan Gainetdinov, ID: 127150

7. novembra 2024

Abstrakt

Cieľom projektu bolo vygenerovať veľký počet náhodných bodov v dvojrozmernom priestore, rozdeliť tieto body do zhlukov (klastrov) pomocou aglomeračného zhlukovania, vypočítať centroidy (medoidy) každého klastru a vizualizovať výsledky.

1 Použité algoritmy

1. **Aglomeratívne zhlukovanie s centroidmi**

   Aglomeratívne zhlukovanie, kde stred je centroid, je hierarchická metóda zhlukovania, ktorá využíva centroid (geometrické ťažisko) na reprezentáciu každého klastru.

   Tento postup funguje takto:

   (a) **Inicializácia:** Každý bod v dátach je na začiatku považovaný za samostatný klaster.

   (b) **Iteratívne spájanie:** V každom kroku sa spoja dva klastre, ktoré sú k sebe najbližšie, pričom vzdialenosť medzi nimi sa určuje na základe vzdialenosti ich centroidov.
   - **Centroid** každého klastru sa vypočíta ako priemer všetkých bodov patriacich do klastru.

   (c) **Postupné spájanie** pokračuje, až kým sa nedosiahne požadovaný počet klastrov alebo určitý maximálny rozostup medzi bodmi v rámci klastru.

2. **Aglomeratívne zhlukovanie s medoidmi**

   Aglomeratívne zhlukovanie, kde stred je medoid, je tiež hierarchická metóda, no s tým rozdielom, že na reprezentáciu klastrov sa namiesto centroidov využívajú medoidy, teda skutočné body z dát. Medoid je bod, ktorý má najmenšiu priemernú vzdialenosť od ostatných bodov v klastri.

   Tento postup funguje nasledovne:

   (a) **Inicializácia:** Na začiatku je každý bod samostatným klastrom.

   (b) **Iteratívne spájanie:** V každom kroku sa spoja dva klastre s najnižšou vzájomnou vzdialenosťou, pričom vzdialenosť sa vypočíta medzi ich medoidmi.
   - **Medoid** je bod, ktorý má najmenší priemerný odstup od ostatných bodov v klastri. Tým je medoid vždy bodom z dát, čo zaisťuje jeho reálnu reprezentatívnosť.

   (c) **Pokračovanie** až kým nedosiahneme požadovaný počet klastrov alebo maximálnu povolenú vzdialenosť v rámci klastrov.

2 Generovanie náhodných bodov

1. **Počiatočné body:** Na začiatku sa náhodne generuje 20 počiatočných bodov v dvojrozmernom priestore so súradnicami v rozsahu od -5000 do 5000. Tieto počiatočné body slúžia ako „základné body" pre ďalšie body.

2. **Ďalšie body:** Následne sa vytvára ďalších 20 000 bodov, pričom každý nový bod je odvodený od jedného z 20 počiatočných bodov. Každý bod sa posúva o náhodný posun (od -100 do 100) v oboch súradniciach **x** a **y**. Tento krok spôsobí, že sa body prirodzene zoskupia okolo počiatočných bodov, čím sa vytvorí jasná štruktúra klastrov.

3 Aglomeratívne zhlukovanie

1. **Výpočet vzdialenostnej matice:** Na výpočet vzdialeností medzi všetkými pármi bodov sa používa euklidovská vzdialenosť pomocou funkcie **pdist** zo **SciPy**.
2. **Aglomeratívne zhlukovanie:** Používame centroidovú metódu, kde vzdialenosť medzi zhlukmi je definovaná vzdialenosťou medzi ich centroidmi. Proces prebieha v týchto krokoch:

   - Na základe vzdialenostnej matice sa vytvorí hierarchický dendrogram (spojením najbližších bodov a klastrov).

   - Z dendrogramu sa vytvorí konečné rozdelenie bodov do klastrov s maximálnou povolenou vzdialenosťou medzi bodmi v rámci jedného klastru nastavenou na 500.

4 Výpočet centroidov a medoidov

4.1 Výpočet centroidov

Centroidy sa vypočítajú ako priemer súradníc bodov patriacich do klastru. Centroid predstavuje ťažisko klastru, avšak môže ležať mimo rozsahu bodov, ak sú body rozmiestnené asymetricky. Realizuje sa pomocou funkcie **evaluate_clusters:**

1. **Zhromaždenie bodov pre každý zhluk:** Vytvára sa slovník, kde každý klaster obsahuje zoznam bodov, ktoré do neho patria.
2. **Výpočet priemerných súradníc:** Pre každý klaster sa vypočíta priemer súradníc X a Y všetkých bodov, čo určí centroid klastru. Centroid predstavuje bod, ktorý najlepšie vystihuje priemernú polohu všetkých bodov v danom zhluku.

4.2 Výpočet medoidov

Medoid je bod v rámci klastru s najnižšou priemernou vzdialenosťou od ostatných bodov v klastri. Výpočet prebieha nasledovne:

1. Pre každý klaster sa vypočíta vzdialenosť medzi každým bodom a všetkými ostatnými bodmi klastru.
2. Priemerná vzdialenosť sa vypočíta pre každý bod v rámci klastru.
3. Bod s najnižšou priemernou vzdialenosťou je vybraný ako medoid, ktorý predstavuje reprezentatívny bod klastru a vždy patrí medzi body klastra.

5 Vizualizácia výsledkov

Vizualizácia je kľúčová pre porovnanie oboch prístupov – centroidov a medoidov. Každý klaster je zobrazený ako skupina bodov, a stredy (centroidy alebo medoidy) sú zvýraznené prázdnymi kruhmi s čiernym okrajom.

5.1 Vizualizácia klasterizacií s centroidami

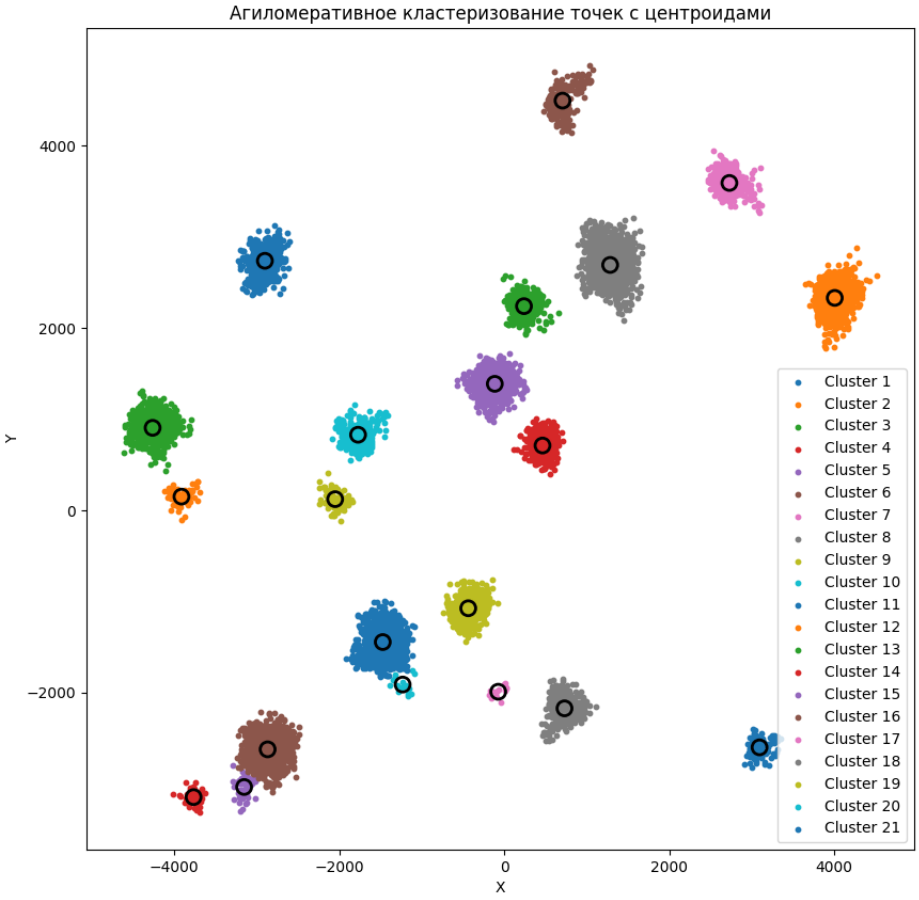
Na nasledujúcom obrazku je klastrovanie s centroidami pri vygenerovaných 10000 bodov. Klastrovanie bolo spravené za **7** sekund.

Ďalší obrazok zobrazuje klastrovanie s centroidami pri vygenerovaných 20000 bodov. Čas spracovania je **15** secund.

5.2 Vizualizácia klasterizacií s medoidami

Na nasledujúcom obrazku je klastrovanie s medoidami pri vygenerovaných 10000 bodov. Klastrovanie bolo spravené za **60** sekund.

Ďalší obrazok je klastrovanie s centroidami pri vygenerovaných 20000 bodov. Klastrovanie bolo spravené za **3** minuty.



Obr. 1: Klastrovanie s centroidami pri 10000 bodov

6 Výpočtová zložitosť algoritmov

6.1 Aglomeratívne zhlukovanie s centroidmi

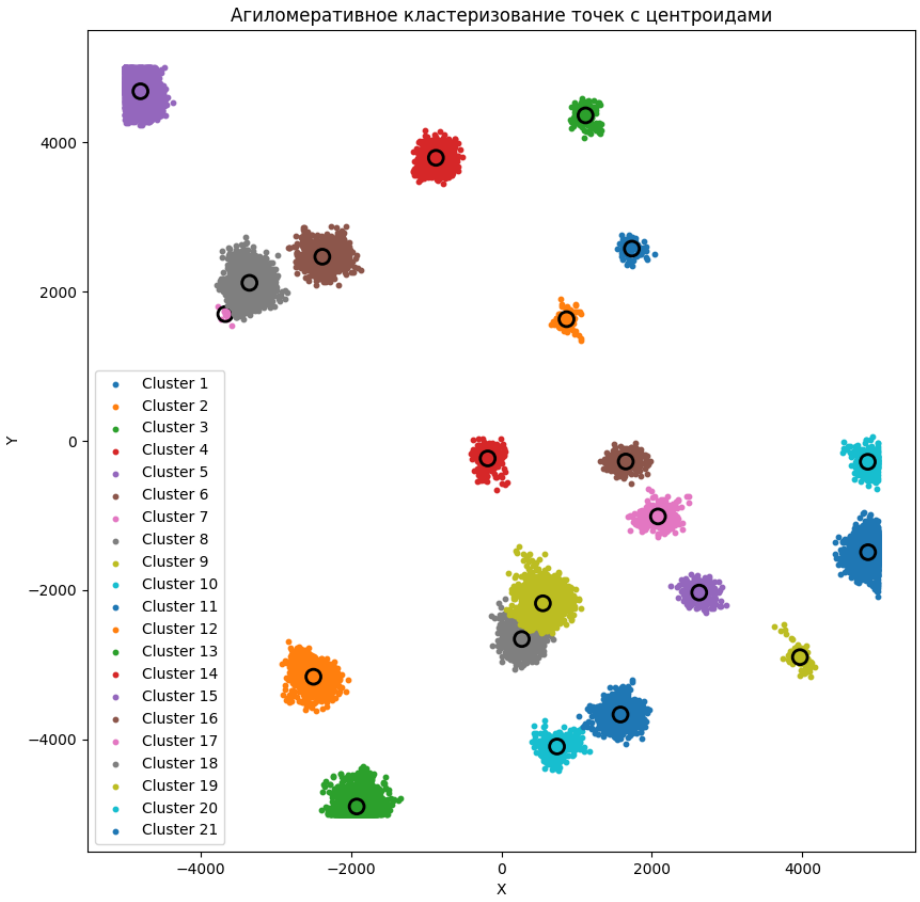
Aglomeratívne zhlukovanie s centroidmi vyžaduje postupné spájanie klastrov podľa vzdialenosti medzi ich centroidmi. Zložitosť je daná najmä počtom bodov a potrebnými výpočtami vzdialeností.

- **Výpočet vzdialenostnej matice:** Na začiatku vypočítame vzdialenosti medzi všetkými dvojicami bodov, čo má zložitosť $O(n^2)$, kde n je počet bodov.
- **Hierarchické spájanie klastrov:** Pri každom kroku hľadáme dvojicu klastrov s najbližšími centroidmi. Tento krok má zložitosť približne $O(n^2 log(n))$, pretože hľadáme najbližšie klastre a následne ich spájame, čo vyžaduje opakované aktualizácie centroidov a vzdialeností.

Celkovo teda zložitosť aglomeratívneho zhlukovania s centroidmi je približne $O(n^2 log(n))$

6.2 Aglomeratívne zhlukovanie s medoidmi

Aglomeratívne zhlukovanie s medoidmi má podobné kroky ako s centroidmi, ale výpočet medoidov je výpočtovo náročnejší, čo zvyšuje zložitosť.



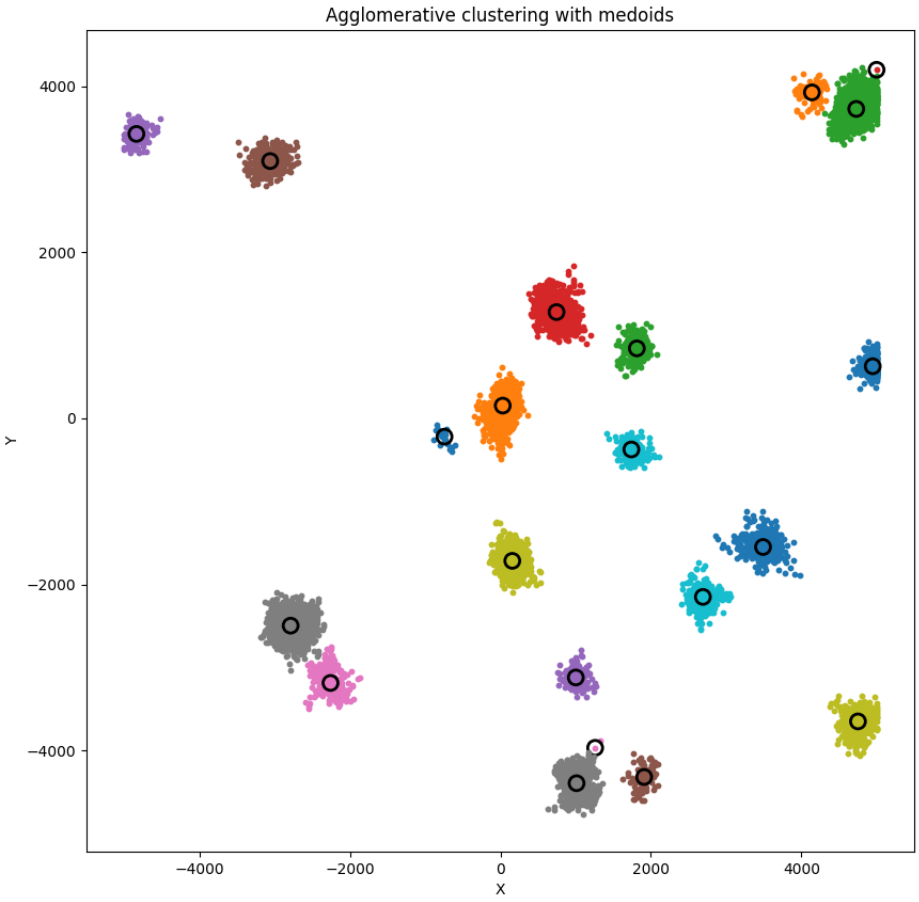
Obr. 2: Klastrovanie s centroidami pri 20000 bodov

- **Výpočet vzdialenostnej matice:** Rovnako ako pri centroidoch, výpočet vzdialeností medzi všetkými pármi bodov má zložitosť $O(n^2)$, kde n je počet bodov.
- **Výpočet medoidov v každom kroku:** Na výpočet medoidu v každom kroku sa musí vypočítať priemerná vzdialenosť medzi každým bodom a všetkými ostatnými bodmi v danom klastri. Pri veľkých klastroch je tento krok náročný, s priemernou zložitosťou $O(n^3)$ v najhoršom prípade, pretože sa v každom kroku prepočítavajú vzdialenosti.
- **Spájanie klastrov a aktualizácia medoidov:** Spájanie klastrov a aktualizácia medoidov môže byť výpočtovo náročná pri veľkých datasetoch. Zložitosť je približne $O(n^3)$.

Celkovo má teda aglomeratívne zhlukovanie s medoidmi zložitosť $O(n^3)$ v najhoršom prípade, čo je podstatne náročnejšie ako pri centroidoch.

7 Porovnanie algoritmov

- Aglomeratívne zhlukovanie s centroidmi: $O(n^2 log(n))$ – rýchlejšie, vhodné pre väčšie datasetové prípady s klastrami približne sférického tvaru.
- Aglomeratívne zhlukovanie s medoidmi: $O(n^3)$ – pomalšie, ale vhodné pre nepravidelné dáta, kde je dôležité, aby každý klaster bol reprezentovaný skutočným bodom.



Obr. 3: Klastrovanie s medoidami pri 10000 bodov

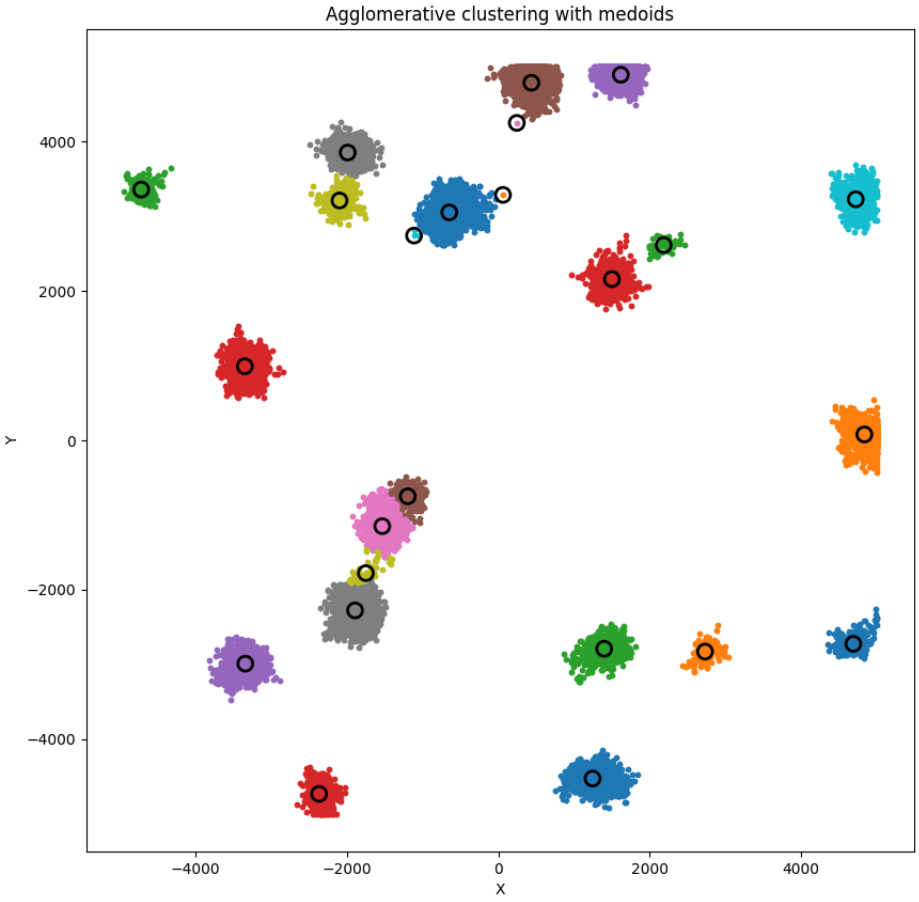
Aglomeratívne zhlukovanie s medoidmi môže byť kvôli vyššej zložitosti ťažšie aplikovať na veľké datasetové problémy, ale často poskytuje reprezentatívnejšie výsledky v nepravidelných dátových štruktúrach.

8 Záver

Oba prístupy, centroidy aj medoidy, poskytujú zaujímavé informácie o štruktúre klastrov:

- **Centroidy** sú ideálne pre hladké a sférické zhluky, ale môžu byť menej reprezentatívne, keď majú body asymetrické rozloženie.
- **Medoidy** poskytujú reprezentatívne stredy, ktoré sú skutočnými bodmi v rámci klastra a preto môžu byť výhodné, keď potrebujeme konkrétne body na ďalšiu analýzu.

Obe techniky sú užitočné pre rôzne typy analýzy, v závislosti od požiadaviek na reprezentatívnosť bodov v klastri.



Obr. 4: Klastrovanie s medoidami pri 20000 bodov