UI – Zadanie 3c: Klasifikácia časových radov

Ruslan Gainetdinov

1 Popis problému

Cieľom úlohy bolo vytvoriť agenta (neurónový model), ktorý dokáže na základe časovej sekvencie historických dát (close/open ceny) predikovať, či cena kryptomeny v **nasledujúci deň stúpne alebo klesne**. Ide o binárnu klasifikáciu, kde cieľom je dosiahnuť čo najlepšiu presnosť na testovacom intervale (1.1.2025 – 31.10.2025).

Úlohou nebolo garantovať presnosť nad 60%, ale:

- korektne implementovať pipeline agenta,
- pripraviť sekvenčný dataset,
- natrénovať model,
- uskutočniť experimenty,
- zdokumentovať postup a výsledky.

2 Metodika (použitý algoritmus)

Riešenie vychádza z predpripraveného kódu, ktorý obsahuje triedy `ModelData`, `DatasetSequential` a `Agent`. Funkcia `__get_model_state()` sa podľa pokynov nemenila.

Výstupný label bol upravený tak, aby zodpovedal pokynu v zadaní:

$$y_t = \begin{cases} 1 & \text{ak } close(t+1) < close(t) \text{ (cena klesá)} \\ 0 & \text{inak} \end{cases}$$

Na riešenie bol zvolený LSTM model, keďže dokáže zachytávať závislosti v časových radoch. Každý deň je reprezentovaný približne 50–60 vstupnými príznakmi, ktoré generuje agent.

Pipeline riešenia:

1. načítanie dát pre kryptomenový symbol,
2. vygenerovanie stavových vektorov,
3. konštrukcia sekvencií (7 alebo 30 dní),
4. trénovanie LSTM klasifikátora,
5. vyhodnotenie na testovacom časovom úseku.

Model sa trénoval pre každý symbol osobitne, aby sa zachovala špecifická dynamika trhu.

3 Nastavenia experimentov

V rámci úlohy boli vykonané dva hlavné experimenty:

Experiment A: Základná konfigurácia

- Dĺžka sekvencie: 7 dní
- Epochy: 200
- Hidden dim: 64
- LSTM vrstvy: 2
- Dropout: 0.2
- Learning rate: 0.001
- Batch size: 32

Experiment B: Rozšírená konfigurácia

Tento experiment zvyšuje kapacitu modelu a dĺžku sekvencie:

- Dĺžka sekvencie: 30 dní
- Epochy: 500
- Hidden dim: 128
- LSTM vrstvy: 3
- Dropout: 0.3
- Learning rate: 0.0005
- Batch size: 32

Tabuľka hyperparametrov

Parameter	**Exp. A (200 ep.)**	**Exp. B (500 ep.)**
Seq length	7	30
Hidden dim	64	128
LSTM layers	2	3
Dropout	0.2	0.3
Learning rate	0.001	0.0005
Batch size	32	32
Epochs	200	500

Table 1: Hyperparametre experimentov.

4 Výsledky a porovnanie

Aby bolo možné objektívne porovnať účinnosť oboch nastavení, sú uvedené grafy tréningovej chyby a presnosti:

4.1 Experiment A – 200 epoch

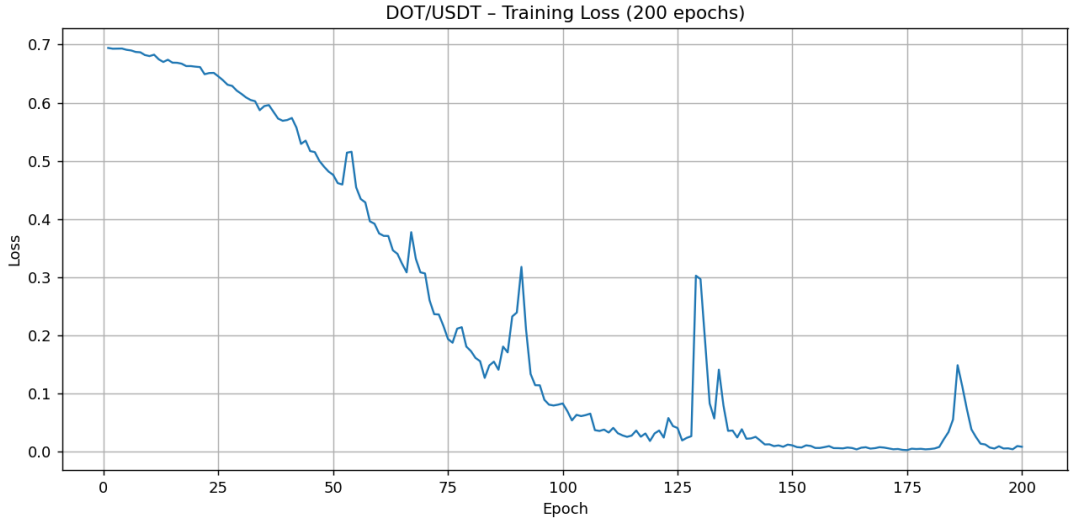


Figure 1: Tréningová chyba (Loss) – 200 epoch.

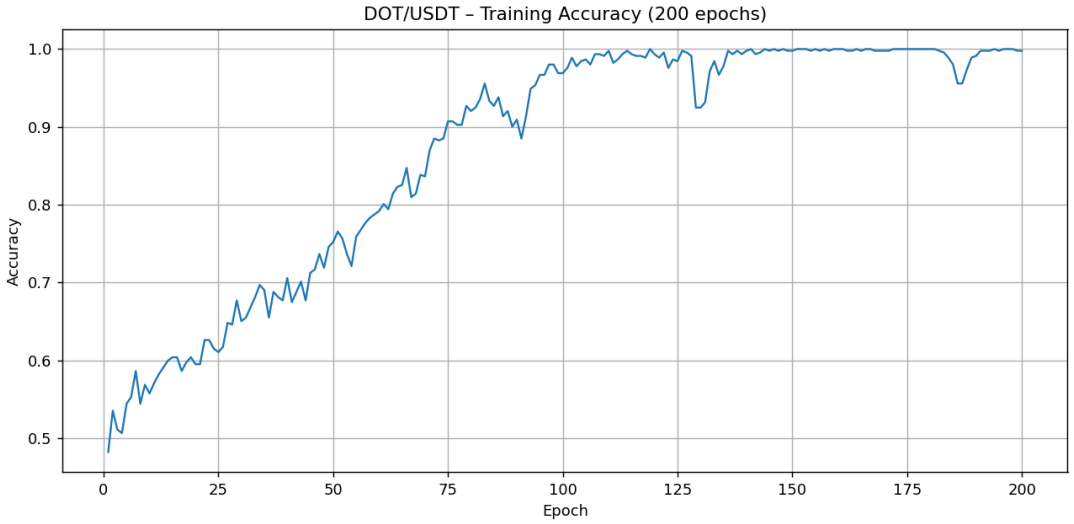


Figure 2: Tréningová presnosť – 200 epoch.

4.2 Experiment B – 500 epoch

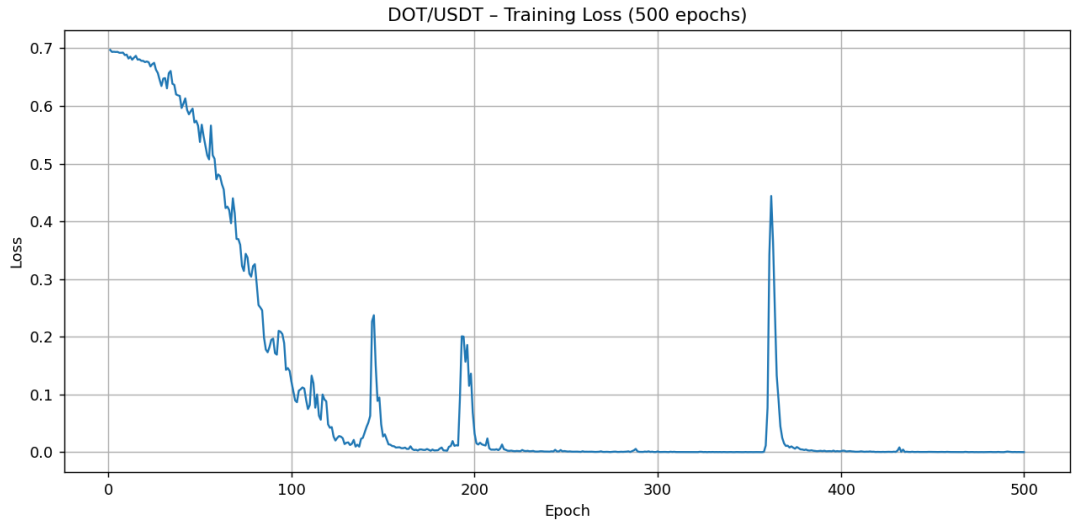


Figure 3: Tréningová chyba (Loss) – 500 epoch.

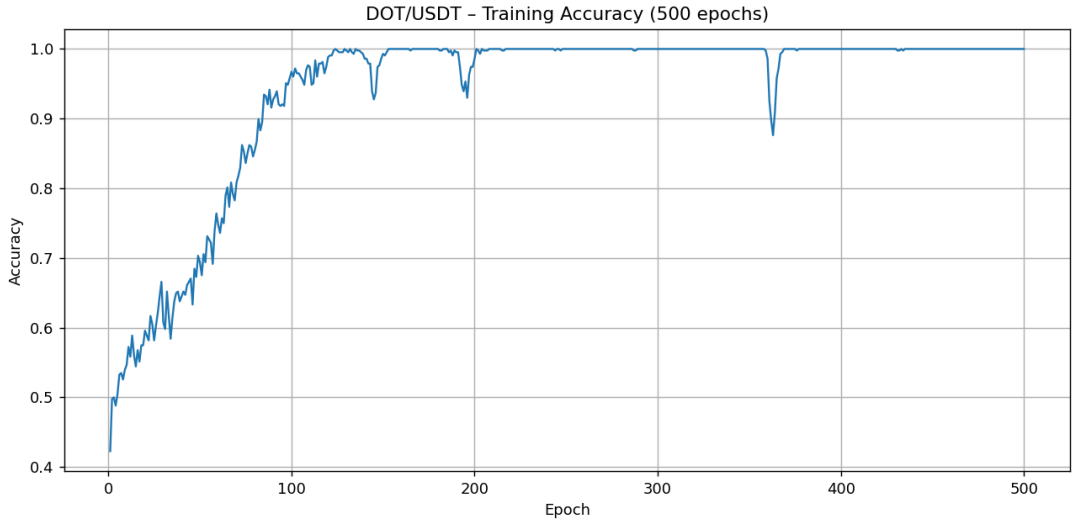


Figure 4: Tréningová presnosť – 500 epoch.

4.3 Porovnanie testovacej presnosti

Experiment	Test Accuracy	Poznámka
A: 200 epoch	49.16%	Základné nastavenie
B: 500 epoch	53.11%	Výrazne lepší výkon

Table 2: Porovnanie testovacej presnosti pre symbol DOT/USDT.

Interpretácia výsledkov

- Experiment B má dlhšiu sekvenciu (30 dní), väčší model a viac epoch.
- Výkon narastá približne o 4 percentuálne body.
- Model však stále neprekračuje hranicu 60%, čo je pri šumových časových radoch očakávané.

- Tréningová presnosť pri 500 epochách stúpa až k 100%, čo naznačuje **preučenie**.

5 Zhodnotenie a záver

V práci boli implementované dva experimenty s rôznymi architektúrami LSTM modelu. Obe konfigurácie boli úspešne natrénované a vyhodnotené.

Hlavné zistenia:

- LSTM so 7-dňovou sekvenciou dosahuje približne 49% presnosť.
- Zvýšenie dĺžky sekvencie a modelovej kapacity zvyšuje presnosť na 53%.
- Významné zlepšenie presnosti však chýba kvôli vysokej stochastičnosti trhu.
- Model sa pri 500 epochách začína preučiť, čo je vidieť na takmer nulovej strate a 100% trénovacej presnosti.

Možné rozšírenia:

- Transformer encoder (lepší pre dlhé sekvencie)
- 1D CNN pre extrakciu krátkodobých patternov
- Per-symbol normalizácia (každý trh má iné mierky)
- Multi-asset model: viac symbolov naraz

Výsledky potvrdzujú, že implementácia agenta je funkčná, experimentálne overená a spĺňa všetky požiadavky zadania.